



<Progress Not Perfection>

[W] Women Techmakers
International Women's Day
Guatemala 2022



Galileo
UNIVERSIDAD




INNOVATIONLAB
galileo

Creando mi primer pipeline en Google Cloud Platform



Mirina Gonzales
@MirinaGonzales
Data Engineer
Women Techmaker Ambassador



Índice

1. Presentación
2. Introducción
3. ¿Qué es un pipeline de datos?
4. ¿Qué es la computación en la nube?
5. Big Data
6. Roles en el mundo de los datos
7. Demo
8. Conclusiones



Mirina Bony Esther Gonzales Rodriguez

Perú

Mirina Gonzales es bachiller de Ingeniera de Sistemas por la Universidad Católica de Santa María, actualmente trabaja como ingeniera de datos en Global66. Participa activamente de comunidades de tecnología y disfruta aprender cosas nuevas sobre Cloud y Big Data. Además es organizadora de GDG Arequipa y Women Techmakers.



Women Techmakers
International Women's Day
Guatemala 2022



GDG Arequipa



Women Techmakers
Arequipa

Data
Engineering
Latam




Datos - Información - Conocimiento



¿Qué es un pipeline de datos?



¿Qué es un pipeline de datos?



¿Qué es la computación en la nube?

On Premise



Cloud



¿Qué es la computación en la nube?

On Premise




Cloud




Cinco características esenciales



Big Data



Las 5 Vs de Big Data



Roles en el mundo de los datos

Ingeniero de datos

- Diseñar y construir el pipeline de datos
- Transformar y limpiar los conjuntos de datos
- Verificar la calidad de los datos

Científico de datos

- Extraer información compleja de los conjuntos de datos.
- Realizar predicciones (ML, AI).
- Crear modelos predictivos.

Analista de datos

- Examinar y combinar múltiples conjuntos de datos para ayudar a negocio a entender las tendencias de los datos



Demo



Google Cloud Platform proyectodata2022

Menú de navegación

- Navegador
- Supervisión
- Configuración

Detalles del bucket

data_raw_iwd

Ubicación: us (varias regiones en Estados Unidos) Clase de almacenamiento: Standard Acceso público: No público Protección: Ninguna

OBJETOS CONFIGURACIÓN PERMISOS PROTECCIÓN CICLO DE VIDA

Depósitos > data_raw_iwd

SUBIR ARCHIVOS SUBIR CARPETA CREAR CARPETA ADMINISTRAR CONSERVACIONES DESCARGAR

Filtrar solo por prefijo de nombre Filtro Filtrar objetos y carpetas

☐	Nombre	Tamaño	Tipo	Fecha de creación	Clase de almacenamiento
☐	data_cats/	—	Carpeta	—	—
☐	data_personajes/	—	Carpeta	—	—
☐	disney_title/	—	Carpeta	—	—
☐	netflix_title/	—	Carpeta	—	—
☐	rm_personajes/	—	Carpeta	—	—



Demo

data_stage_iwd					
Ubicación		Clase de almacenamiento	Acceso público	Protección	
us (varias regiones en Estados Unidos)		Standard	No público	Ninguna	
OBJETOS		CONFIGURACIÓN	PERMISOS	PROTECCIÓN	CICLO DE VIDA
Depósitos > data_stage_iwd					
SUBIR ARCHIVOS SUBIR CARPETA CREAR CARPETA ADMINISTRAR CONSERVACIONES DESCAR					
Filtrar solo por prefijo de nombre Filtro Filtrar objetos y carpetas					
☐	Nombre	Tamaño	Tipo	Fecha de creación ?	Clase de alm
☐	dis_movies/	—	Carpeta	—	—
☐	disney_tvshow/	—	Carpeta	—	—

<https://www.kaggle.com/shivamb/disney-movies-and-tv-shows>



Demo



Configuración de instancia de Data Fusion

Data Fusion

← Crear instancia de Data Fusion

Nombre de la instancia *

df-instancia

Solo caracteres alfanuméricos, espacios y guiones (-); p. ej.: Mi nombre de instancia-1024.
El nombre debe comenzar con una letra y contener hasta 30 caracteres.

ID de instancia

df-instancia

Descripción

Región

us-west1

La región en la que se crea la instancia.

Versión

6.5.1

Edición

☒ Developer

Esta edición proporciona todas las características para la exploración de productos y entornos de desarrollo con disponibilidad zonal y límites sobre el entorno de ejecución.

☐ Básico

Esta edición proporciona capacidades completas de integración de datos. Los usuarios pueden compilar canalizaciones de datos por lotes, conectarse a cualquier fuente de datos y realizar transformaciones sin código. Hay una limitación para las ejecuciones de canalizaciones simultáneas. Se recomienda para entornos no vitales.

☐ Enterprise

Esta edición proporciona todas las funciones de la edición básica. Además, incluye compatibilidad con canalizaciones de datos en tiempo real, interacciones con linaje de datos, ausencia de limitaciones para las ejecuciones de canalizaciones simultáneas y alta disponibilidad. Se recomienda para entornos vitales.

Data Fusion

Instancias

+

CREAR INSTANCIA

↻

ACTUALIZAR

🗑

BORRAR


ACTUALIZAR

Selecciona la instancia de Cloud Data Fusion que deseas ver.

☐	●	Nombre de la instancia	Acción	Edición	Región	Zona	Versión
☐	✓	df-instancia-data	Ver instancia 🔗	Developer	us-west1	us-west1-c	6.5.1 (latest version) 💡

<


Demo



Primera pantalla de Data Fusion



Demo



< Connections in "default"

Upload

BigQuery(2) ▾

Database(0) ▾

GCS(2) ▴

Cloud Storage Default

Sample Buckets

Kafka(0) ▾

MySQL(0) ▾

Oracle(0) ▾

PostgreSQL(0) ▾

S3(0) ▾

Spanner(1) ▾

SQL Server(0) ▾


Select Data

Root

9 buckets

Search this directory

Name	Type
data_raw_iwd	bucket
dataprep-staging-9a38d1cc-d7e2-4b7f-ac7f-88e8d9dc62c0	bucket



Demo



Upload	Root / data_raw_iwd	5 directories
BigQuery(2) ▾	Name	Type
Database(0) ▾	data_cats	directory
	data_personajes	directory
GCS(2) ^	disney_title	directory
	netflix_title	directory
Cloud Storage Default	rm_personajes	directory
Sample Buckets		

Demo

Upload	Root / data_raw_iwd	5 directories
BigQuery(2) ▾	Name	Type
Database(0) ▾	data_cats	directory
GCS(2) ▴	data_personajes	directory
	disney_title	directory
Cloud Storage Default ⋮	netflix_title	directory
Sample Buckets ⋮	rm_personajes	directory

Upload	Root / data_raw_iwd / disney_title
BigQuery(2) ▾	Name
Database(0) ▾	disney_plus_titles.csv
GCS(2) ▴	
Cloud Storage Default ⋮	

Demo



Cloud Data Fusion | Wrangler

OPERATIONS HUB SYSTEM ADMIN Developer Edition

disney_plus_titles.csv x

Cloud Storage Default - data_raw_iwd/disney_title/disney_plus_titles.csv

disney_plus_titles.csv

Data Insights

Create a Pipeline More

String

body

	show_id,type,title,director,cast,country,date_added,release_year,rating,duration,listed_in,description
1	s1,Movie,Duck the Halls: A Mickey Mouse Christmas Special,"Alonso Ramirez Ramos, Dave Wasson","Chris Diamantopoulos, Tony Anselmo, Tress MacNeille, Bill Farmer, Russi Taylor, Corey Burton",,"November 26, 2021",,"PG",91 min,Comedy,Santa Claus passes his magic bag to a new St. Nic.
2	s2,Movie,Ernest Saves Christmas,John Cherry,"Jim Varney, Noelle Parker, Douglas Seale",,"November 26, 2021",,"PG",91 min,Comedy,Santa Claus passes his magic bag to a new St. Nic.
3	s3,Movie,Ice Age: A Mammoth Christmas,Karen Disher,"Raymond Albert Romano, John Leguizamo, Denis Leary, Queen Latifah",United States,"November 26, 2021",,"TV-G",23 min,"Animation, Comedy, Family",Sid the sloth is back and he's got a new friend.
4	s4,Movie,The Queen Family Singalong,Hamish Hamilton,"Darren Criss, Adam Lambert, Derek Hough, Alexander Jean, Fall Out Boy, Jimmie Allen",,"November 26, 2021",,"TV-PG",41 min,Musical,"This is real life, not just a show."
5	s5,TV Show,The Beatles: Get Back,"John Lennon, Paul McCartney, George Harrison, Ringo Starr",,"November 25, 2021",,"2021",,"1 Season","Docuseries, Historical, Music",A three-part documentary from Peter Jackson capturing the final days of the band.
6	s6,Movie,Becoming...Cristina,"Cristina Escobar, Vincent Cassel",United States,"November 24, 2021",,"2021",,"PG-13",94 min,"Biographical, Documentary",An inside look at the legendary life of adventure.

Columns (1)


Transformation steps (0)

Search


Column names

	#	Name	Completion
	1	body	100%

Demo



Dividir columnas



Demo

Columns (13)			Transformation steps (1)
Search			Column names ▼
☒	#	Name	Completion
☐	1	body	100%
☐	2	show_id	100%
☐	3	type	100%
☐	4	title	100%
☐	5	director	60.2%
☐	6	cast	86.6%
☐	7	country	79.3%
☐	8	date_added	100%
☐	9	release_year	100%
☐	10	rating	99.6%
☐	11	duration	100%
☐	12	listed_in	100%
☐	13	description	100%



Demo



Pasos para la transformación (Recetas)

		Create a Pipeline	More
Columns (6)		Transformation steps (4)	
#	Transformations		
1	parse-as-csv :body ',' true	✕	
2	drop :body	✕	
3	filter-rows-on regex-not-match type ^TV Show\$	✕	
4	drop :director,:cast,:rating,:duration,:listed_in,des...	✕	

		Create a Pipeline	More
Columns (12)		Transformation steps (3)	
#	Transformations		
1	parse-as-csv :body ',' true	✕	
2	drop :body	✕	
3	filter-rows-on regex-not-match type ^Movie\$	✕	



Demo



Properties Documentation

Label *

GCS Disney

Connection

Use Connection

☒ Yes

Connection

Cloud Storage Default

BROWSE CONNECTIONS

Basic

Reference Name *


data_raw_jwd_disney_titledisney_plus_titles.csv

BROWSE

Path *

gs://data_raw_jwd_disney_title/disney_plus_titles.csv

Demo



No errors found. [Validate](#)

Basic

Reference Name *
disney_movies ?

Project ID
auto-detect ? (M)



Path *
gs://data_stage_iwd/disney_movies ? (M)

Path Suffix
yyyy-MM-dd-HH-mm ? (M)

Format *
csv ? (M)



Demo



Demo



Time	Level ▾	Message
03/12/2022 8:42:23	INFO	Pipeline '314d3981-a20a-11ec-84e0-36ad53d7374a' is started by user 'root'
03/12/2022 8:42:23	INFO	Pipeline '314d3981-a20a-11ec-84e0-36ad53d7374a' running
03/12/2022 8:42:53	INFO	Pipeline '314d3981-a20a-11ec-84e0-36ad53d7374a' succeeded.

data_stage_iwd

Ubicación

us (varias regiones en Estados Unidos)

Clase de almacenamiento

Standard

Acceso público

No público

Protección

Ninguna

OBJETOS

CONFIGURACIÓN

PERMISOS

PROTECCIÓN

CICLO DE VIDA

Depósitos > data_stage_iwd > disney_movies

SUBIR ARCHIVOS

SUBIR CARPETA

CREAR CARPETA

ADMINISTRAR CONSERVACIONES

DESCARGAR

BORRAR

Filtrar solo por prefijo de nombre ▾

Filtro Filtrar objetos y carpetas

☐

Nombre

Tamaño

Tipo

Fecha de creación ?

Clase de almacenamiento

Última modificación

Acceso público ?

No hay filas para mostrar



Demo

Configure schedule for pipeline Pipeline_movies_v1 ✕

Basic | Advanced

Pipeline run repeats

Daily ▾

Repeats every

1 ▾

 day(s)

Starting at

1 ▾

 :

0 ▾

AM ▾

Summary

This pipeline is scheduled to run everyday, at 1:00AM.
The pipeline cannot have concurrent runs.



Max concurrent runs

1 ▾


Save Schedule



Demo



Demo





"After careful consideration of all 437 charts, graphs, and metrics, I've decided to throw up my hands, hit the liquor store, and get snookered. Who's with me?!"



Conclusiones




- En el mundo de los datos existen distintos roles (Ingeniero de Datos, Científicos de datos, Analistas de Negocios).
- Las nubes nos ofrecen diferentes servicios para construir pipelines.
- Los pipelines se construyen respondiendo la necesidad del requerimiento.



Creando mi primer pipeline en Google Cloud Platform



Mirina Gonzales
@MirinaGonzales
Data Engineer
Women Techmaker Ambassador





GRACIAS por su atención

[W] Women Techmakers
International Women's Day
Guatemala 2022



Galileo
UNIVERSIDAD



INNOVATIONLAB
galileo