



spéa ea ker.

Mirina Bony Esther Gonzales

Data Engineer - Global66



Ingeniera de Sistemas en la Universidad Católica de Santa María. Actualmente es embajadora de Women Techmakers. Está certificada como AWS Solution Architect-associate. Actualmente se desempeña como data engineer.

Hobbies: Leer, caminar y viajar.

"Aprender cosas nuevas es como abrir cajitas en mi cabeza"

 [mirina-gonzales-rodriguez](#)



AWS
User Groups



¿Cómo los servicios serverless de AWS pueden facilitar el análisis de encuestas?

- Esta es una charla sobre datos!

Mirina Gonzales Rodriguez

AGENDA



1. **Introducción**
2. **Los servicios que usaremos de AWS**
3. **Presentación del problema**
4. **Presentación de la arquitectura**
5. **Solución**
6. **Preguntas**

Los servicios



AWS
User Groups

¿Qué servicios usaremos?



Lenguaje de alto nivel de programación interpretado cuya filosofía hace hincapié en la legibilidad de su código



Apache Spark es un Framework de código abierto desarrollado por el AMPLab de la UC Berkeley que permite procesar bases de datos masivas mediante computación distribuida, una técnica que consiste en explotar varias unidades de computación distribuidas en clusters en beneficio de un mismo proyecto para dividir el tiempo de ejecución de una consulta.

AWS

User Groups

¿Qué servicios usaremos?



Amazon Simple Storage
Service (Amazon S3)



AWS Glue



Crawler



AWS Glue
Data Catalog



Amazon Athena



Amazon QuickSight



AWS Secrets Manager



AWS Identity and Access
Management (IAM)

AWS
User Groups

Caso a trabajar



Presentación:

Somos Punto alto & Punto bajo, una empresa enfocada en el diseño, fabricación y venta de piezas originales tejidas a mano. Entre nuestras piezas destacan: carteras, mantas, bufandas, almohadas entre otros productos. Nuestros productos están elaborados con hilos de alta calidad. Además brindamos talleres para aprender a tejer con crochet o agujas



AWS

User Groups

Caso a trabajar



Problemática:

La empresa quiere conocer un poco más a sus clientes, para lograrlo realizó un estudio de mercado. Además a las personas que compraron algún producto les pidió llenar una encuesta que mida el NPS. Ellos desean visualizar los datos de una manera sencilla y rápida y que con el tiempo no sea necesario que intervenga alguno de sus colaboradores.



AWS

User Groups

La solución



Pasos del proceso

1. Identificar las fuentes
2. Entender el problema
3. Diseñar el pipeline
4. Levantar servicios transversales
5. Subir / obtener los datos desde las fuentes
6. Limpiar la información
7. Automatizar el proceso
8. Crear un panel que muestre los resultados

AWS

User Groups

La solución




Pasos del proceso

1. Identificar las fuentes
2. Entender el problema
3. Diseñar el pipeline
4. Levantar los ambientes
5. Subir / obtener los datos desde las fuentes
6. Limpiar la información
7. Automatizar el proceso
8. Crear un panel que muestre los resultados

Tenemos dos fuentes:


- Archivo csv de las respuestas de la encuesta
- La API de TypeForm



AWS

User Groups

La arquitectura



Permisos en IAM



Políticas de permisos (8) [Información](#)

Puede asociar hasta 10 políticas administradas.

🔍 Filtre las políticas por propiedad o nombre de política y pulse Intro.

☐	Nombre de la política ↗	Tipo
☐	+ PassRole-IAM	Administrada por el cliente
☐	+ AWSQuickSightListIAM	Administrada por AWS
☐	+ AWSQuickSightReadWrite	Administrada por AWS
☐	+ AWSQuickSightAthenaAccess	Administrada por AWS
☐	+ AmazonS3FullAccess	Administrada por AWS
☐	+ AmazonAthenaFullAccess	Administrada por AWS
☐	+ AWSQuickSightToTAnalyticsAccess	Administrada por AWS
☐	+ AWSGlueConsoleFullAccess	Administrada por AWS

Crear grupo con permisos sobre los servicios que usaremos

AWS
User Groups

☐	Nombre de la política ↗	Tipo
☐	+ PassRole-IAM	Administrada por el cliente
☐	+ AWSQuickSightReadWrite	Administrada por AWS
☐	+ AmazonS3FullAccess	Administrada por AWS
☐	+ AWSGlueServiceRole	Administrada por AWS
☐	+ AWSGlueConsoleFullAcc...	Administrada por AWS

Crear un rol para los jobs de Glue

Configuración de S3

Buckets creados

	Nombre ▲	Región de AWS ▼	Acceso ▼
☐	aws-glue-assets-435355006240-us-east-1	EE. UU. Este (Norte de Virginia) us-east-1	Bucket y objetos que no son públicos
☐	wo-data-origen	EE. UU. Este (Norte de Virginia) us-east-1	Bucket y objetos que no son públicos
☐	wo-data-procesada	EE. UU. Este (Norte de Virginia) us-east-1	Bucket y objetos que no son públicos

	Nombre ▲	Tipo ▼
☐	formularios/	Carpeta
☐	typeform_encuestas/	Carpeta

wo-data-origen

	Nombre ▲	Tipo ▼
☐	encuestas_nps/	Carpeta
☐	estudio_de_mercado/	Carpeta

wo-data-procesada

Procesar csv de respuestas



AWS
User Groups

1. Configuraciones y librerías



Importación de aws wrangler

```
[2]: %additional_python_modules awswrangler

Welcome to the Glue Interactive Sessions Kernel
For more information on available magic commands, please type %help in any new cell.

Please view our Getting Started page to access the most up-to-date information on the Interactive
eractive-sessions.html
Installed kernel version: 0.37.0
Additional python modules to be included:
awswrangler

[13]: #---- Librerías python ----#
import json
import datetime
import boto3
import pandas as pd
import numpy as np
import awswrangler as wr
```

Configuraciones para visualizar pandas

```
[4]: #Configuracion de pandas
pd.set_option('display.max_columns', None)
pd.set_option('display.max_rows', None)
```

AWS

User Groups

2. Leer fuente

Leer datos usando awswrangler

- Es importante encontrar la mejor forma de leer los datos
- Renombrar ayuda a trabajar mejor con las columnas
- Crear variables informativas

```
[15]: path_source='s3://wo-data-origen/formularios/Estudio_De_mercado_puntoalto_puntona.csv'

[16]: #cargar datos desde s3 usando awswrangler
      df = wr.s3.read_csv(path=path_source)
```

Renombrar columnas

```
[21]: #Renombrar columnas
      df = df.rename(columns={'Marca temporal':'fecha_registro',
                             '¿Cuál es tu rango de edad?':'rango_de_edad',
                             'Género':'genero',
                             '¿Actualmente eres?':'ocupacion_actual',
                             '¿Alguna has comprado una pieza tejida a mano?':'a_compraste_una_pieza_tejida',
                             '¿Que pieza compraste?':'a_pieza_tejida_comprada',
                             'La pieza era para ti o era un regalo':'a_propio_uso_o_regalo',
                             '¿Por qué elegiste esa pieza?':'a_motivacion_para_comprar',
                             '¿Cuanto pagaste por la pieza?':'a_precio_de_la_pieza',
                             'Si tuvieras que elegir entre uno de los siguientes productos ¿Cuál sería?':'b_producto_elegido',
                             '¿Te gustaría ser parte de algun taller de tejido para crear tu primera pieza con nosotros?':'asistiras_al_taller',
                             '¿Cuanto estarías dispuesto a pagar por la pieza elegida anteriormente?':'b_cuanto_pagarias_por_el_producto_elegido',
                             'Si quieres ser de los primeros en enterarte de nuestro lanzamiento dejanos tu correo. No te preocupes no lo compartir'
                             })
```


2. Seleccionar columnas



- Almacenar sólo lo que usará

```
[22]: #Seleccionar columnas
df = df[['fecha_registro', 'rango_de_edad', 'genero', 'ocupacion_actual',
        'a_compraste_una_pieza_tejida', 'a_pieza_tejida_comprada',
        'a_propio_uso_o_regalo', 'a_motivacion_para_comprar',
        'b_producto_elegido', 'b_cuanto_pagarias_por_el_producto_elegido',
        'asistiras_al_taller', 'correo_electronico']]
```

3. Limpieza y formatear columnas



- Limpiar los datos ayuda un mejor procesamiento
- Tener definiciones previas facilitan el trabajo
- Uniformizar las columnas

```
[28]: #Limpiar columna 1. poner a todos minusculas 2. renombrar posibles opciones
df['a_pieza_tejida_comprada'] = df['a_pieza_tejida_comprada'].str.lower()

[29]: df['a_pieza_tejida_comprada'] = df['a_pieza_tejida_comprada'].replace({'una chompa ': 'chompa',
                                                                           'un saco': 'saco',
                                                                           'unos guantes': 'guantes',
                                                                           'un gorro': 'gorro'})

[30]: #Llenar informacion nan - no_information
df['a_pieza_tejida_comprada'] = df['a_pieza_tejida_comprada'].replace(np.nan, 'no_information')
```


4. Guardar los datos



- Usar un formato que facilite el proceso
- Usar un formato de Athena reconozca

```
[37]: path_tarjet = 's3://wo-data-procesada/estudio_de_mercado/em_puntoalto_puntobajo/'
```

```
[24]: #Guardar la informacion usando la libreria wrangler
wr.s3.to_parquet(
    df = df,
    path=path_tarjet,
    dataset=True
)

{'paths': ['s3://wo-data-procesada/estudio_de_mercado/em_puntoalto_puntobajo/5241bfa866df44e2a95c7cb2d55a63b4.snappy.parquet'],
```

Crear una base de datos en Glue



db_puntoalto_puntobajo

Last updated (UTC)
March 7, 2023 at 21:41:23

Edit

Delete

Database properties

Name	Description	Location	Created on (UTC)
db_puntoalto_puntobajo	-	-	March 7, 2023 at 05:17:38

Tables (1)

Last updated (UTC)
March 7, 2023 at 21:41:25

Delete

Data quality New

Add tables using crawler

Add table

View and manage all available tables.

Filter tables

< 1 > ⚙

☐	Name	Database	Location	Classification	Deprecated	View data
☐	em_puntoalto_puntobajo	db_puntoalto_puntobajo	s3://wo-data-procesada/estu	parquet	-	Table data

¿Qué hace el crawler?



AWS Glue > Crawlers > wo_crawler_encuestas

wo_crawler_encuestas

Last updated (UTC) March 7, 2023 at 21:40:18 [Refresh](#) [Run crawler](#) [Edit](#) [Delete](#)

Crawler properties

Name	IAM role	Database	State
wo_crawler_encuestas	Glue-ServiceRole	db_puntoalto_puntobajo	READY
Description	Security configuration	Lake Formation configuration	Table prefix
-	-	-	-

Registrar fuentes de S3

Crawler runs | Schedule | **Data sources** | Classifiers | Tags

Data sources (1) [Info](#) [Refresh](#)

The list of data sources to be scanned by the crawler.

	Type	Data source	Parameters
☐	S3	s3://wo-data-procesada/estudio_de_mercado/em_puntoalto_puntobajo/	Recrawl all

AWS

User Groups

Consultar datos en Athena

Consultar los datos usando SQL

Data source

AwsDataCatalog ▼

Database

db_puntoalto_puntobajo ▼

Tables and views Create ▼ ⚙️

🔍 Filter tables and views

▼ Tables (1) < 1 >

+ em_puntoalto_puntobajo ⋮

```
1 SELECT * FROM "db_puntoalto_puntobajo"."em_puntoalto_puntobajo" limit 10;
```

SQL Ln 1, Col 74

Run again Explain Cancel Clear Create ▼ ⚙️ Reuse query results
*Athena engine version 3 only

Query results Query stats

Completed Time in queue: 130 ms Run time: 619 ms Data scanned: 3.01 KB

Results (10) Copy Download results

🔍 Search rows

#	fecha_registro	rango_de_edad	genero	ocupacion_actual	a_compraste_una_pieza_tejada	a_pieza_tejada_comprada	a_propio_uso_o
1	21/9/2022 1:58:49	22 años - 26 años	Varón	Trabajador	Sí	bufanda	uso_personal
2	21/9/2022 2:11:29	22 años - 26 años	Mujer	Estudiante	Sí	bufanda	uso_personal

Procesar encuestas desde la API

AWS
User Groups



¿Cómo me conecto a la API?



- Entender cómo funciona la API para extraer datos
- Generar el API token para conectarse con los permisos necesarios
- Conocer límites de consulta de la API

LOS ÁMBITOS DE ESTE TOKEN

Cuentas	Leer
Formularios	Leer/Escribir
Imágenes	Leer/Escribir
Respuestas	Leer/Escribir
Temas	Leer/Escribir
Webhooks	Leer/Escribir

Cuenta

Tus opciones

Comunicación

Autorizaciones

Tokens personales

Tokens personales
Aquí están los tokens que registraste para usar una de las APIs de Typeform

NOMBRE DEL TOKEN

nps-token

Creado en 28 feb 2023

Ver ámbitos

...

¿Cómo mantener seguro el secret-key?



- Con Secret Manager podemos mantener a salvo las api keys.
- En un Secreto podemos guardar más de un valor
- Los datos se almacenan en clave - valor
- Facilita el cambio del valor

Detalles del secreto	
Clave de cifrado aws/secretsmanager	Descripción del secreto -
Nombre del secreto prod_datateam	
ARN del secreto arn:aws:secretsmanager:us-east-1:435355006240:secret:prod_datateam-Y06hpX	

Clave-valor		Texto no cifrado
Clave de secreto	Valor del secreto	
ApiKey-typeform	Bearer tfp_7MJc56d8KCT1FyGbRUZ4iY8kuergfQLLk3NXsB1GQ77B_3sp6wwJdX2RA9J	

AWS

User Groups

¿Cómo extraer los datos desde la API?



- Definimos las librerías de Python y las de Pyspark

```
#-----Glue import-----#
import sys
from awsglue.transforms import *
from awsglue.utils import getResolvedOptions
from pyspark.context import SparkContext
from awsglue.context import GlueContext
from awsglue.job import Job

sc = SparkContext.getOrCreate()
glueContext = GlueContext(sc)
spark = glueContext.spark_session
job = Job(glueContext)

#---- Librerias python ----#
import requests
import json
import datetime
import boto3
import pandas as pd
```

AWS

User Groups

Leer el valor del secret key



```
#####  
#                               SECRETMANAGER  
#####  
def get_secret():  
    secret_name = "prod_datateam"  
    region_name = "us-east-1"  
  
    # Create a Secrets Manager client  
    session = boto3.session.Session()  
    client = session.client(  
        service_name='secretsmanager',  
        region_name=region_name  
    )  
    try:  
        print("calling secret")  
        get_secret_value_response = client.get_secret_value(  
            SecretId=secret_name  
        )
```

```
#-----Call secret-----#  
#Rescatar secretos  
secrets = get_secret()  
#Seleccionar secreto  
ApiKey = secrets['ApiKey-typeform']
```

calling secret

AWS

User Groups

Consultar API



- Averiguar qué necesita recibir la API al ser llamada
- Extraer los datos de la respuesta de la API

```
[9]: def extraer_preguntas(url):  
    args = {}  
    headers = {'content-type': 'application/json',  
              'Authorization' : ApiKey}  
    r = requests.get(url, params=args, headers=headers)  
    status_code_api = r.status_code  
  
    if r.status_code == 200:  
        print("La api respondió exitosamente")  
        json_data = r.json()  
        return json_data  
    else:  
        print("Error calling API-> status_code_error " + str(status_code_api))  
        json_data = r.json()  
        return json_data
```

AWS

User Groups

Función para guardar datos en Json



- Nos apoyamos de la librería boto3
- Guardar en el formato de la fuente, ayuda a recuperarnos ante algún cambio

```
[3]: def expS3_json(data,bucket_tarjet,path_tarjet):  
      print("-----Function: expS3_json -----")  
      s3 = boto3.resource('s3')  
      s3object = s3.Object(bucket_tarjet, path_tarjet)  
      s3object.put(Body=(bytes(json.dumps(data).encode('UTF-8'))))  
      print("El archivo se guardo en:" + bucket_tarjet + '/' + path_tarjet)
```

Correr proceso



- Definir la url a llamar a la API
- Guardar los datos
- Al usar funciones podemos reutilizar la función y evitar tener código duplicado

```
bucket_tarjet = 'wo-data-origen'

form_id = 'JEnTLfm1'
url = 'https://api.typeform.com/forms/{form_id}'

path_tarjet = f'typeform_encuestas/{form_id}/preguntas/questions_{form_id}.json'
print(path_tarjet)
```

```
data = extraer_preguntas(url)

La api respondio exitosamente

expS3_json(data,bucket_tarjet,path_tarjet)

-----Function: exp_json_s3 -----
File has been saved wo-data-origen/typeform_encuestas/JEnTLfm1/preguntas/questions.json
```

AWS

User Groups

Gracias!



AWS
User Groups



Gracias

AWS
User Groups