

Datos de calidad:

El éxito de tu modelo empieza
antes del entrenamiento



Mirina Gonzales Rodriguez
Data Engineer en Yape

Hola!

Soy Mirina Gonzales

- Estudié Ingeniería de Sistemas
- He trabajado en roles como DataOps, MLOps y Data Engineer
- Embajadora de Women Techmakers y Organizadora de Google Developer Group Arequipa
- Mentora en el programa de mentorías TechFem Monterrey



<https://www.linkedin.com/in/mirina-gonzales-rodriguez/>



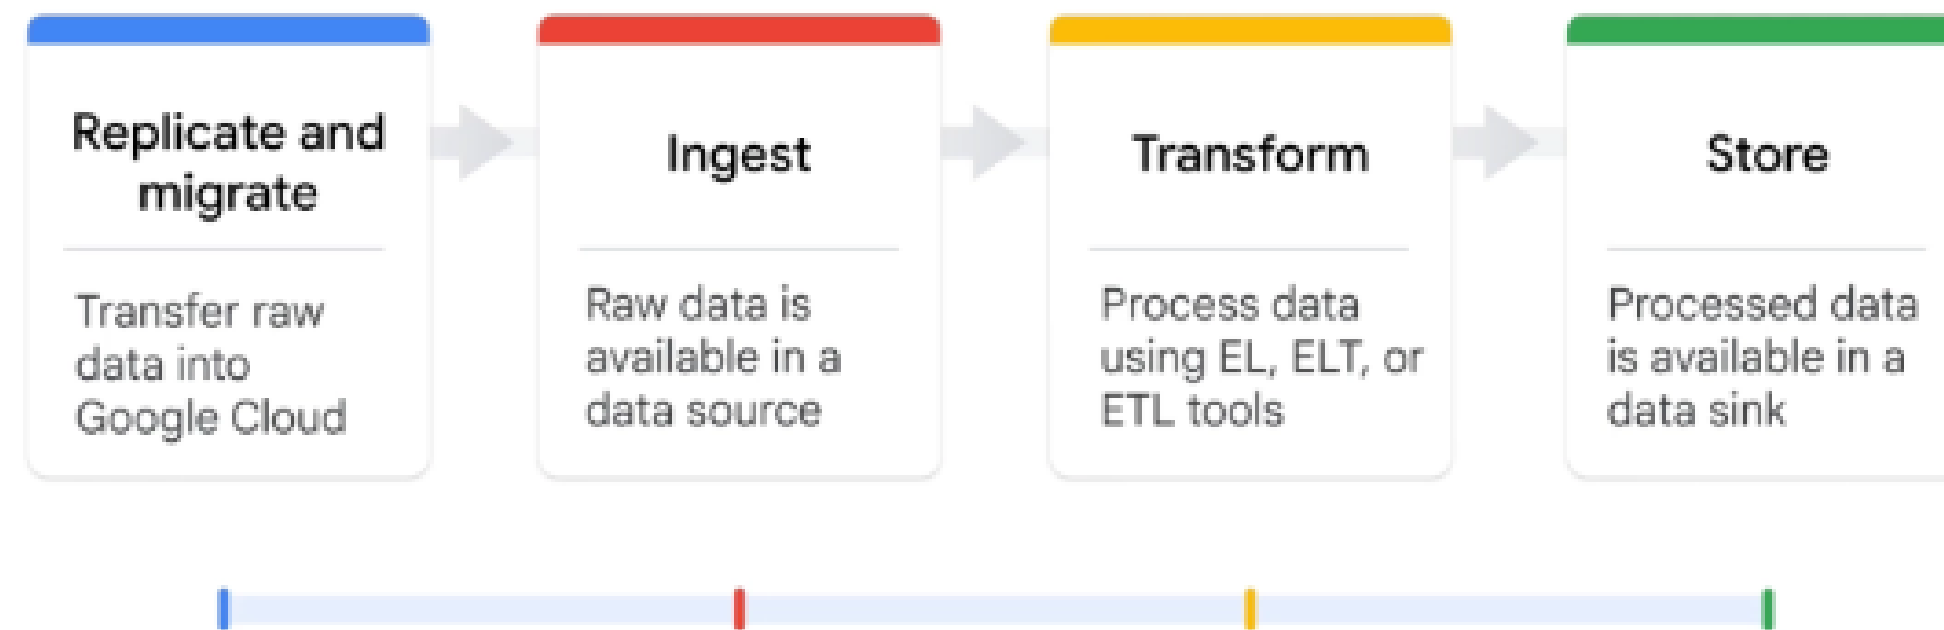
hola.miriii

Los pasos antes elegir un modelo ...



El flujo de la Ingeniería de datos

Data engineering tasks evolve around ingesting, transforming, and storing data



Google Cloud



Lo primero: Entender el problema



1. **Identificar el verdadero problema:** Enfocarse en el problema real, no solo en el aspecto técnico.
2. **Evaluar la necesidad de un modelo:** Determinar si realmente se necesita un modelo o si hay alternativas para resolverlo.
3. **Definir el éxito del proyecto:** Establecer métricas, dashboards, plazos de entrega, etc para medir el éxito del proyecto.





Entender

La fuente de datos



1. **¿De dónde vienen los datos?** - Transaccionales, logs, APIs, scraping, encuestas.
2. **¿Con qué frecuencia se actualizan?** — batch vs streaming.
3. **¿Hay documentación / diccionario de datos?**
4. **Data profiling inicial:** distribuciones, cardinalidad, rango de fechas, registros duplicados

Datos Personales Identificables (Datos sensibles)

Personally Identifiable information (PII)

Es cualquier información que identifique a la persona:

- Nombre completo
- Fecha de nacimiento
- Dirección de la calle
- Número de teléfono
- Tarjeta del Seguro Social
- Información de la tarjeta de crédito
- Número de cuenta bancaria
- Número de pasaporte



Proteger a las personas

Data Ethics



"Abarca obligaciones morales de recopilar, proteger y utilizar información de identificar datos personales"

Buscamos proteger a las personas detrás de los datos.

Proteger a las personas

Principios de la Ética de Datos



1. **Propiedad:** Cada persona es dueña de sus datos, es necesario el consentimiento para su recopilación. Nunca se debe dar por sentado el consentimiento.
2. **Transparencia:** Se debe transparentar como se planea recopilar, almacenar y usarla. Redactar una política que el usuario pueda conocer
3. **Privacidad:** No permitir que los datos Sensibles se compartan públicamente, anonimizar los datos.
4. **Intención:** La intención detrás de recopilar, almacenar, guardar y usar los datos. Son relevantes los datos que solicito para resolver mi problema.
5. **Resultados:** Analizar el impacto que puede generar

Analisis Exploratorio de datos (EDA)



- Es un método utilizado para descubrir los datos que estamos trabajando.
- Su objetivo es analizar los datos antes de hacer suposiciones.
- Ayuda a confirmar que se esté haciendo las preguntas correctas.



Analisis Exploratorio de datos (EDA)

Descubrir

Identificar patrones, tendencias y relaciones en los datos.

Estructurar

Organizar los datos de manera que sean comprensibles y útiles para el análisis.

Limpiar

Eliminar o corregir datos erróneos o inconsistentes para asegurar la calidad del análisis.

Unir

Combinar diferentes conjuntos de datos para obtener una visión más completa.

Validar

Asegurarse de que los datos sean precisos y relevantes para el análisis.

Presentar

Comunicar los hallazgos de manera efectiva a través de gráficas.

Casos reales



El Problema:

Zillow intentó usar IA para predecir precios y comprar casas automáticamente (iBuying), pero el modelo operaba fuera de su contexto validado.

Qué pasó?

El sistema no pudo manejar la volatilidad del mercado post-pandemia y errores manuales en los atributos de las propiedades (como typos en códigos postales o número de habitaciones).

<https://www.shackleford.coach/ai-leadership-insights/zillow-lost-881-million-the-ai-was-working-perfectly>

Casos reales




El Problema: Un algoritmo de Optum, usado para identificar pacientes que necesitaban cuidados intensivos, subestimaba sistemáticamente la salud de pacientes afroamericanos.

Qué pasó?

Se usó el historico de pacientes atendidos. Dado que históricamente se gasta menos en pacientes negros por razones socioeconómicas, el modelo "aprendió" que estaban más sanos de lo que realmente estaban.

<https://www.bmj.com/content/367/bmj.l6232>

Casos reales



El Problema:

En 1999, la sonda de \$125 millones de dólares se desintegró al entrar en la atmósfera de Marte.

Qué pasó?

Un equipo de ingeniería utilizó unidades inglesas (libra-fuerza) para los cálculos de impulso, mientras que el software de navegación esperaba unidades métricas (Newtons).

<https://science.nasa.gov/mission/mars-climate-orbiter/>



Conclusiones



- El primer paso no es elegir el modelo.
- Trabajar con datos nos otorga una gran responsabilidad sobre los mismos.
- Debemos cuestionarnos el uso y fin de los datos que usamos.

Datos de calidad:

El éxito de tu modelo empieza
antes del entrenamiento

Mirina Gonzales Rodriguez

Data Engineer en Yape

Organizadora GDG Arequipa

Embajadora WTM



<https://www.linkedin.com/in/mirina-gonzales-rodriguez/>



hola.miriii