1ra Edición

Del caos a las respuestas:

Tu primera ruta en ingeniería de datos





Mirina Gonzales
Ingeniera de Datos
Embajadora Women Techmakers

aws DuocUC

AWS SBG Chile
Student Builder Groups Chile

aws Student COMMUNITY DAY CHILE



Mirina Gonzales

- Ingeniera de Sistema por la Universidad Católica de Santa Maria
- Data Engineer con más de 5 años en AWS, Databricks y Azure
- Women Techmakers Ambassador | Organizadora de GDG Arequipa
- Databricks Certified Data Engineer Associate
- Speaker y community builder

1ra Edición

¿Cuántos sismos hubo mientras yo hablaba?

Lo respondemos al final de la charla, con datos reales.



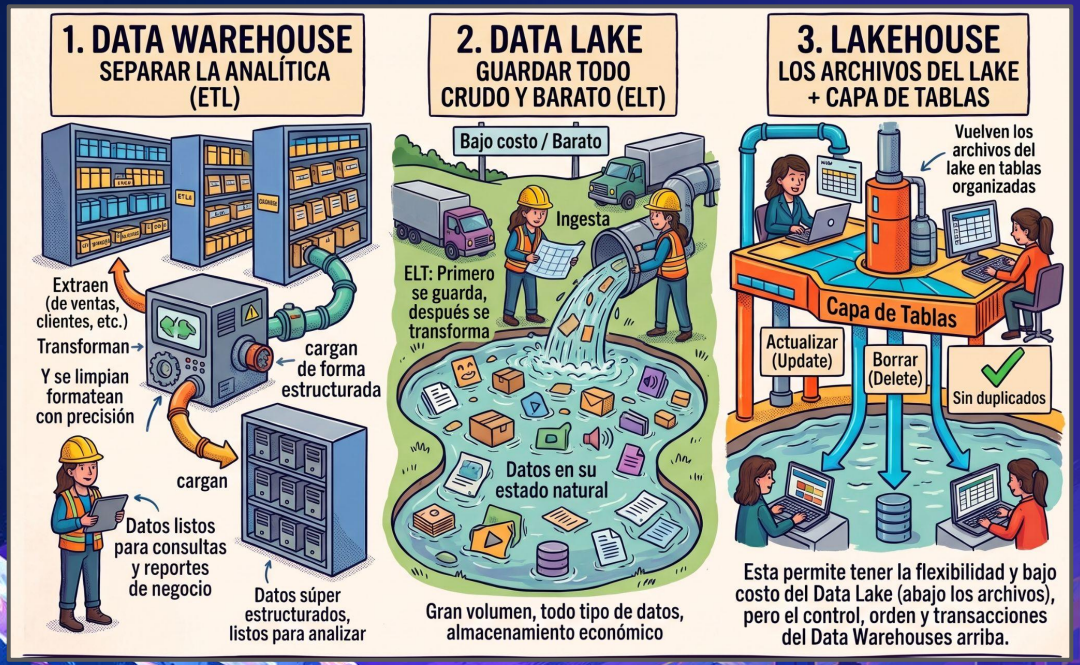
aws DuocUC AWS SBG Chile
Student Builder Groups Chile

Las empresas y sus datos



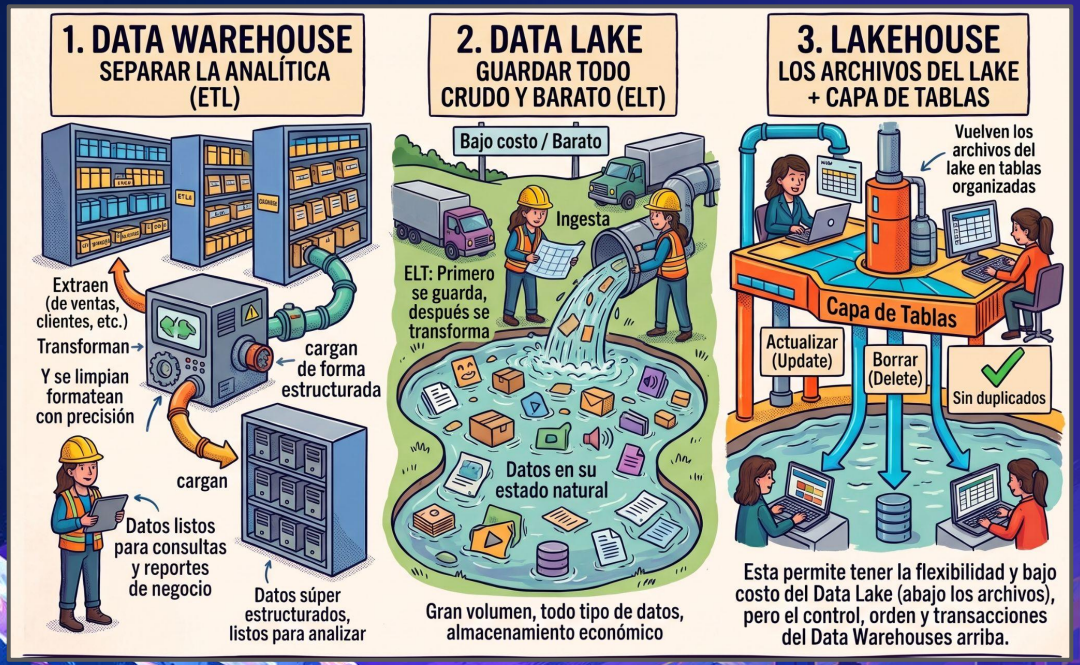
Del caos al lakehouse

Las empresas buscan soluciones para sacarle valor a sus datos.



Del caos al lakehouse

Las empresas buscan soluciones para sacarle valor a sus datos.

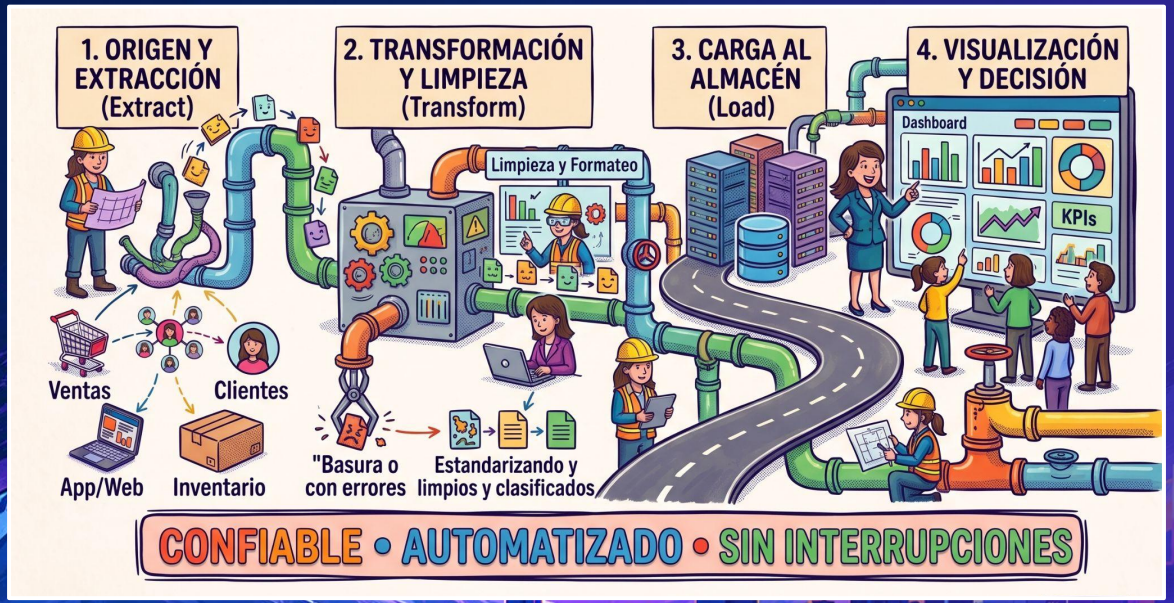


Y ¿quién hace que todo este viaje funcione?

¿Qué es la ingeniería de datos?

aws Student COMMUNITY DAY CHILE

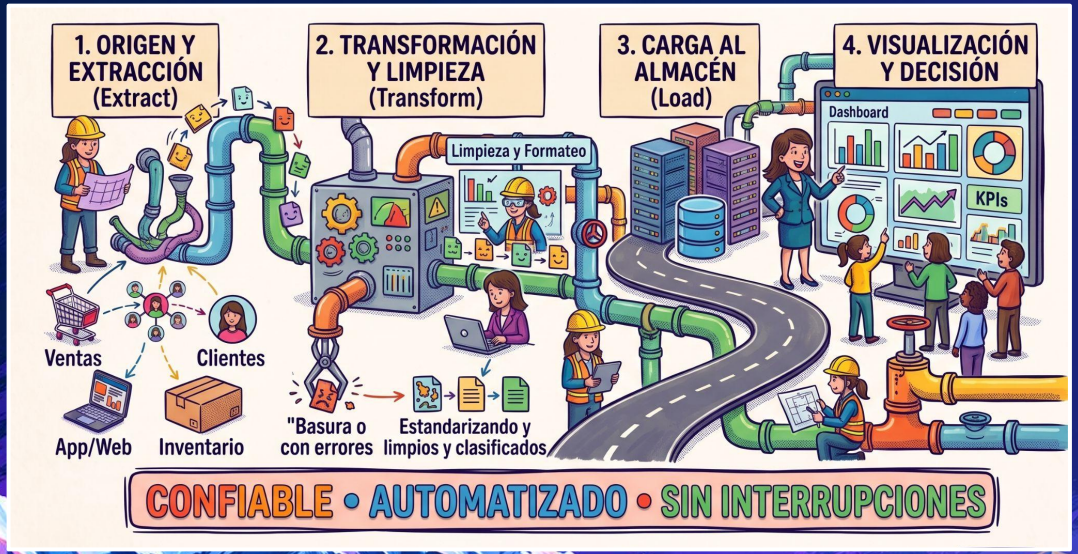
Diseñar y construir los sistemas que llevan datos crudos desde donde nacen hasta donde alguien los usa para decidir.



¿Qué es la ingeniería de datos?

aws Student COMMUNITY DAY CHILE

Diseñar y construir los sistemas que llevan datos crudos desde donde nacen hasta donde alguien los usa para decidir.



Si alguien responde preguntas con datos, el DE es quien construye la carretera por donde viajan los datos para construir esas respuestas. Si la carretera falla, nadie llega a ningún lado.

Y quién construye esta carretera?

¿Qué hace un/a DE?

aws Student COMMUNITY DAY CHILE

- **Ingestar**: Trae los datos desde diferentes fuente
- **Limpiar y validar:** Formato de fechas, quitar duplicados
- **Modelar:** Tablas, las capas del Lakehouse
- **Orquestar:** La ejecución de los flujos sin intervención humana
- **Monitorear:** Alertas sobre los errores, límites de costos
- **Automatizar:** Implementar despliegues automáticos
- **Cuidar costos y seguridad**



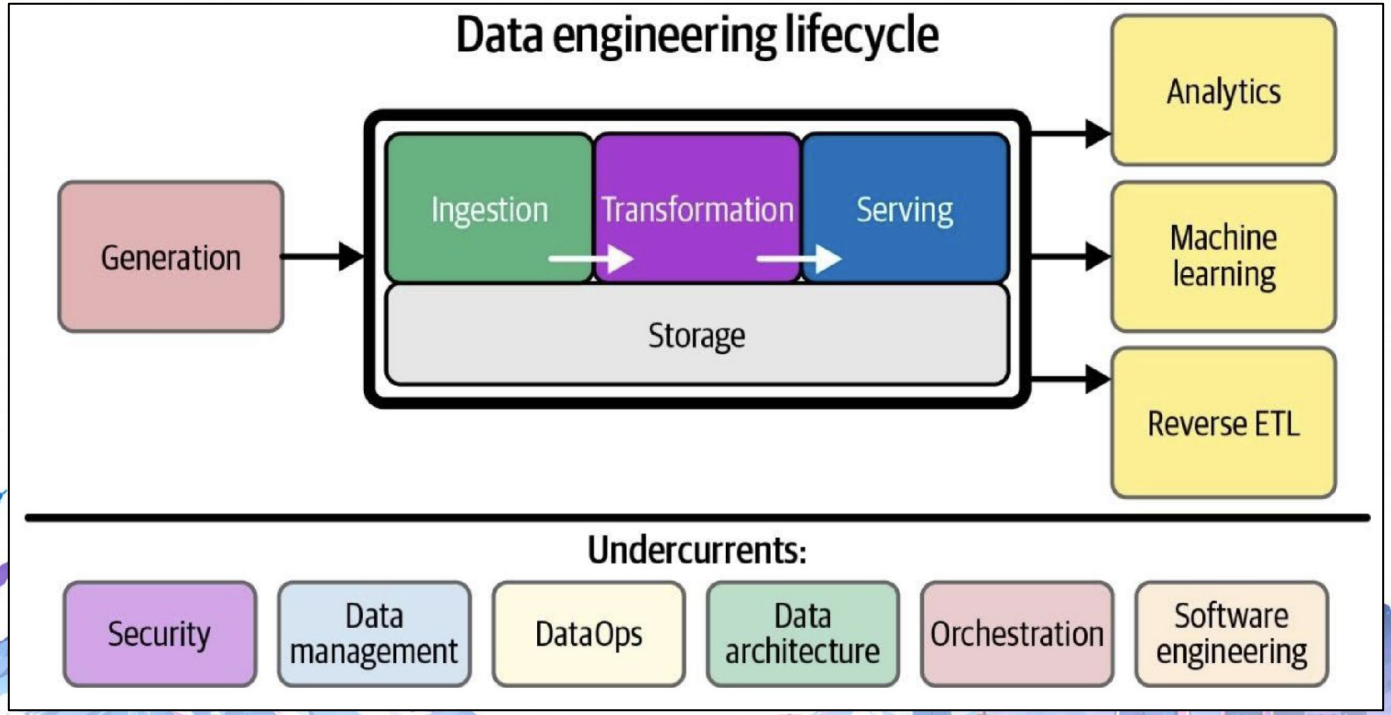
¿Qué hace un/a DE?

aws Student COMMUNITY DAY CHILE

- **Ingestar**: Trae los datos desde diferentes fuente
- **Limpiar y validar:** Formato de fechas, quitar duplicados
- **Modelar:** Tablas, las capas del Lakehouse
- **Orquestar:** La ejecución de los flujos sin intervención humana
- **Monitorear:** Alertas sobre los errores, límites de costos
- **Automatizar:** Implementar despliegues automáticos
- **Cuidar costos y seguridad**

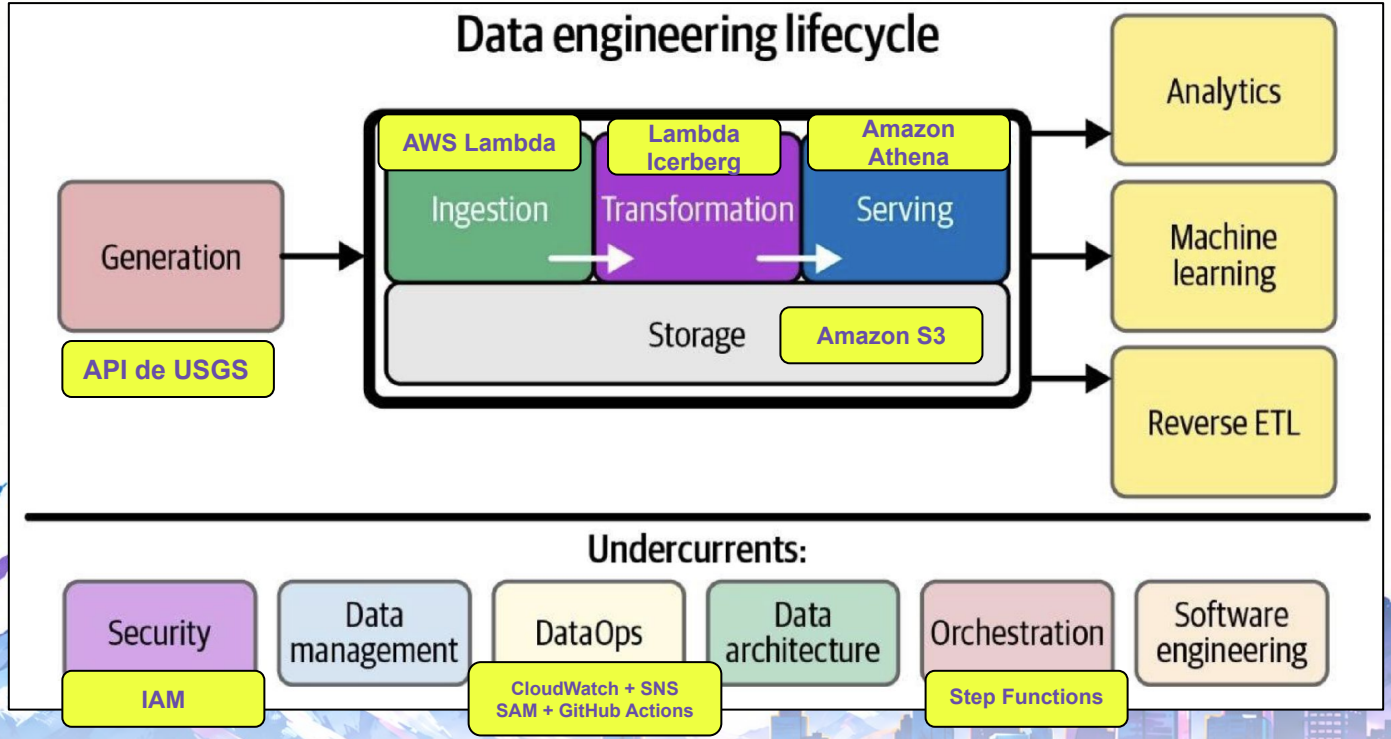
Todas estas tareas siguen un camino. Ese camino tiene nombre.

Ciclo de vida del dato

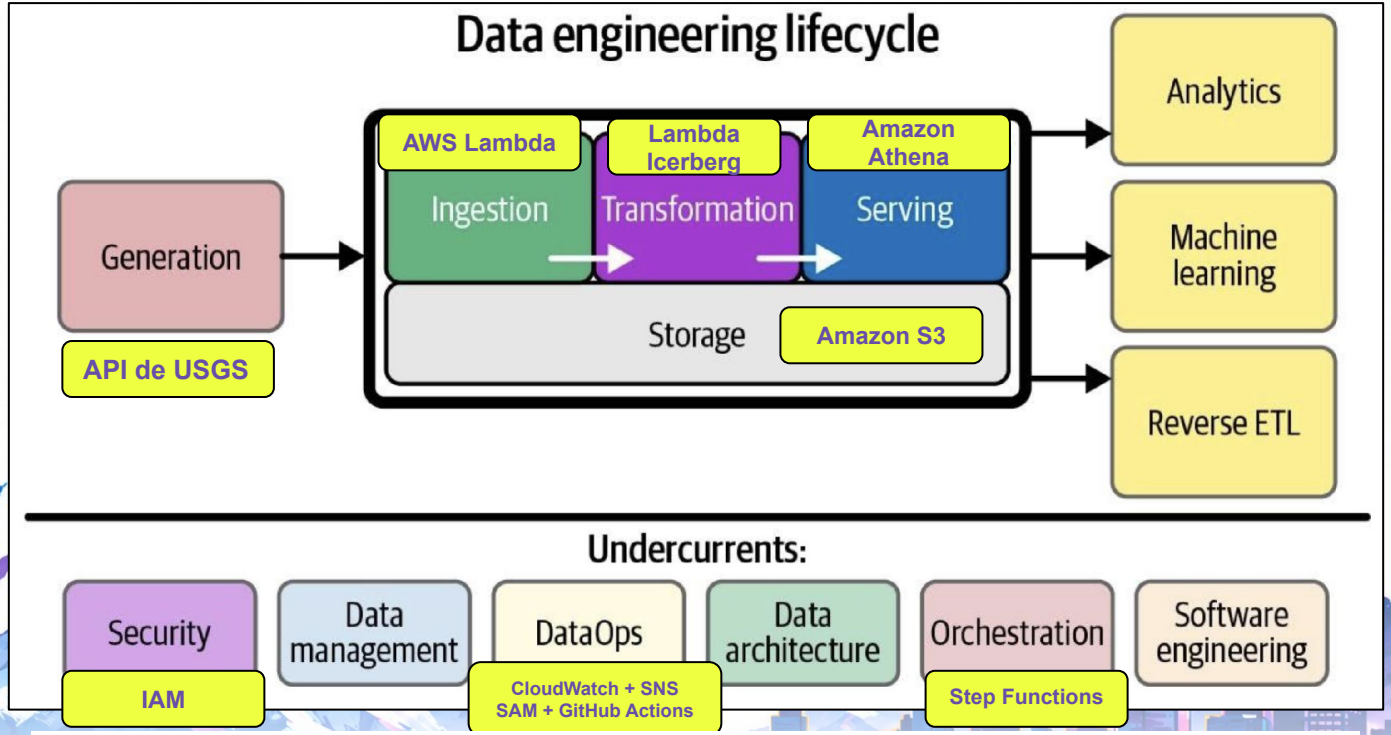


Reis, J. y Housley, M. (2022). *Fundamentals of Data Engineering: Plan and Build Robust Data Systems*. O'Reilly Media.

Ciclo de vida del dato



Ciclo de vida del dato



Empecemos por la ingesta: cómo consumir los datos?

Qué tipo de Ingesta elegir?

aws Student COMMUNITY DAY CHILE

Se responde según la necesidad del negocio y considerando los costos y tiempos.

Preguntas	Opciones
¿Cada cuánto necesito el dato?	Batch / Streaming
¿Cuánto traigo cada vez?	Full Load / incremental / CDC
¿Quién inicia?	Pull / push

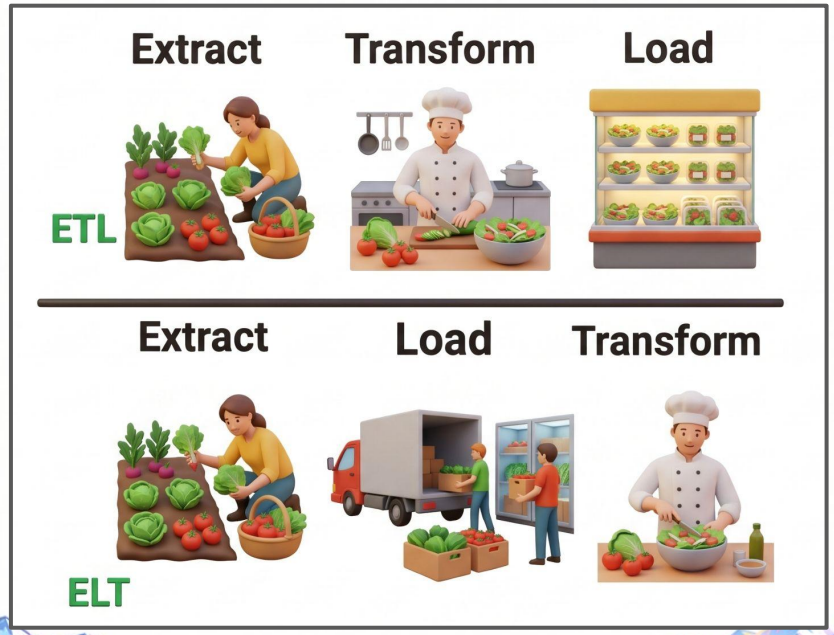
Qué tipo de Ingesta elegir?

Se responde según la necesidad del negocio y considerando los costos y tiempos.

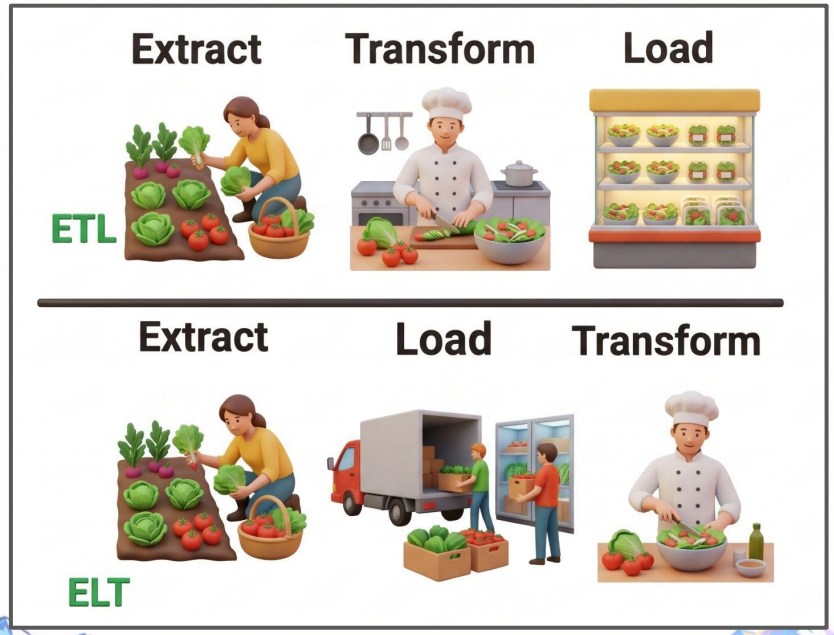
Preguntas	Opciones
¿Cada cuánto necesito el dato?	Batch / Streaming
¿Cuánto traigo cada vez?	Full Load / incremental / CDC
¿Quién inicia?	Pull / push

Ya tenemos la ingesta. Ahora debo transformar los datos antes o después de guardarlos?

ETL vs ELT



ETL vs ELT

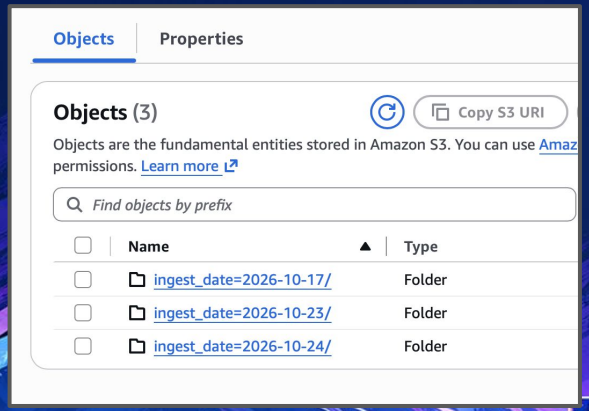


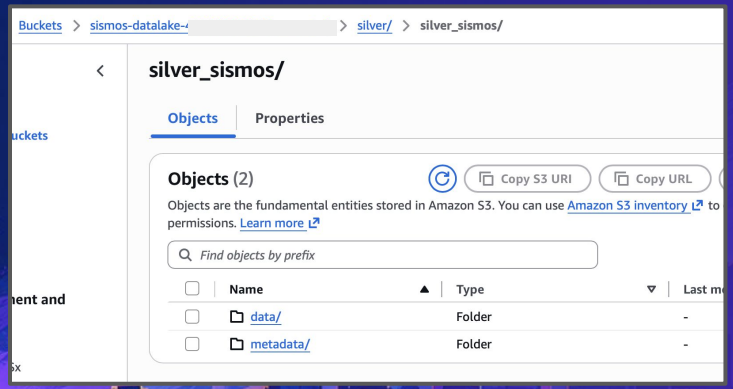
Y si guardo todo, ¿cómo guardo para que sea rápido y barato de consultar?

Almacenamiento: formatos y tablas

aws Student COMMUNITY DAY CHILE

1. **Fila vs columna:**
   a. Por Fila: CSV/JSON
   b. Por columna: Parquet
2. **Particiones:** carpetas por fecha, para leer solo lo necesario.
3. **Formatos de tabla abiertos:** Iceberg, Delta, Hudi → actualizar, borrar y cambiar el esquema sobre archivos en S3



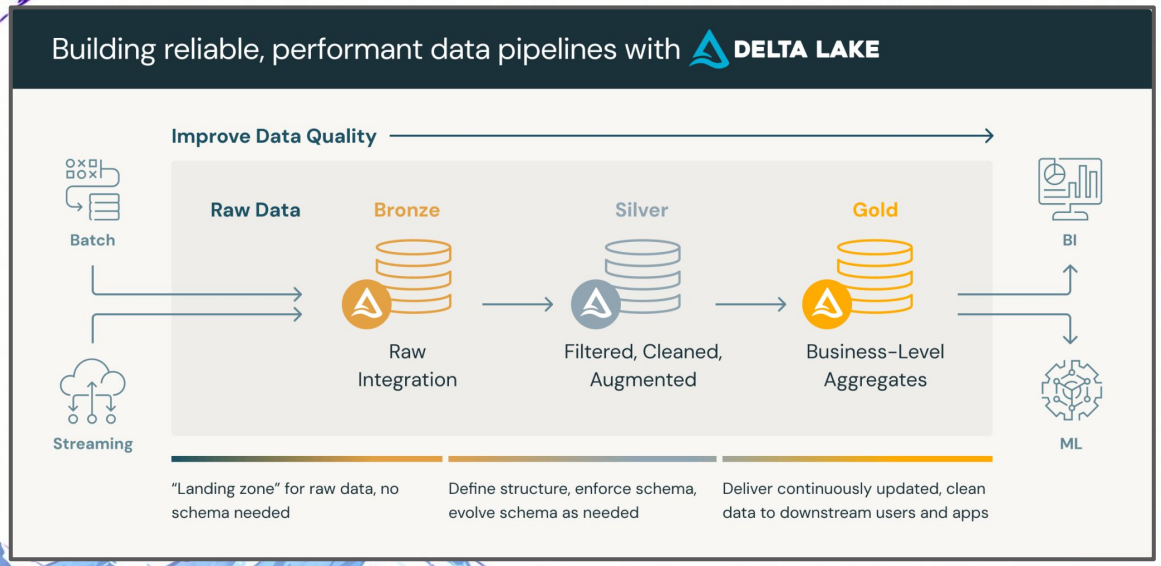


Almacenamiento: formatos y tablas

1. **Fila vs columna:**
   a. Por Fila: CSV/JSON
   b. Por columna: Parquet
2. **Particiones:** carpetas por fecha, para leer solo lo necesario.
3. **Formatos de tabla abiertos:** Iceberg, Delta, Hudi → actualizar, borrar y cambiar el esquema sobre archivos en S3

Ya sabemos cómo guardar. Ahora, ¿cómo organizo el camino desde los datos crudos hasta las respuestas

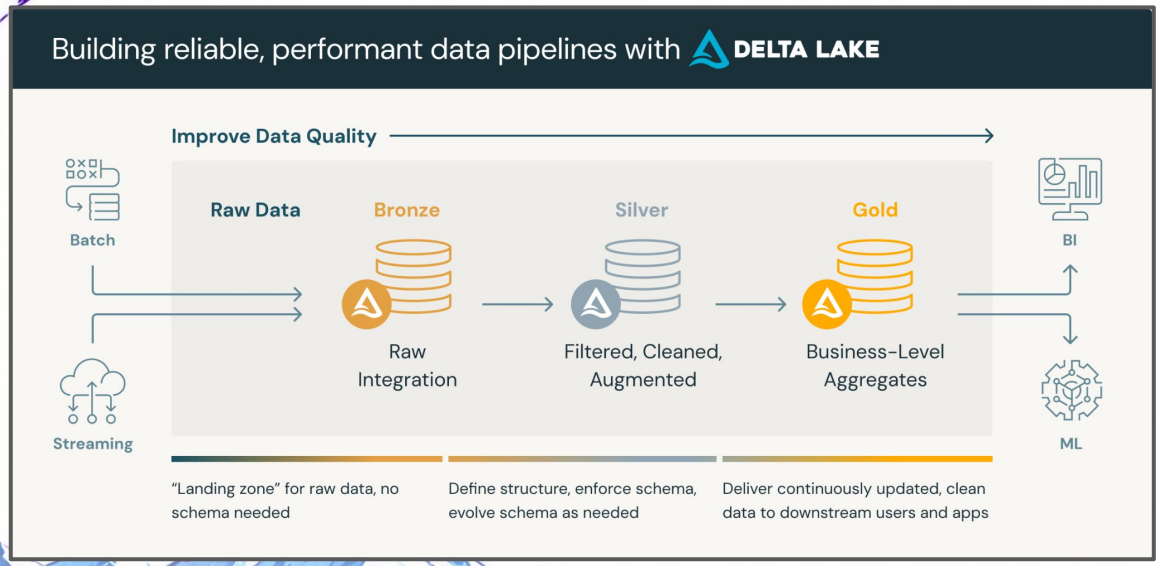
Medallion: Calidad y observabilidad



En AWS las llaman: Raw, Stage y Analytics

- **Bronze** es la copia fiel de lo que llegó
- **Silver** es el dato limpio: tipos correctos, fechas legibles, sin duplicados. Es la tabla en la que se puede confiar.
- **Gold** es la respuesta lista para el negocio: métricas, resúmenes, lo que se muestra en el dashboard.

Medallion: Calidad y observabilidad



En AWS las llaman: Raw, Stage y Analytics

- **Bronze** es la copia fiel de lo que llegó
- **Silver** es el dato limpio: tipos correctos, fechas legibles, sin duplicados. Es la tabla en la que se puede confiar.
- **Gold** es la respuesta lista para el negocio: métricas, resúmenes, lo que se muestra en el dashboard.

Pero, ¿cómo sé que lo que hay en silver es correcto?

Calidad y observabilidad



¿Cuántos sismos hubo mientras yo hablaba?

Lo respondemos al final de la charla, con datos reales.



1ra Edición

Demo

De la API de USGS a una respuesta en Athena



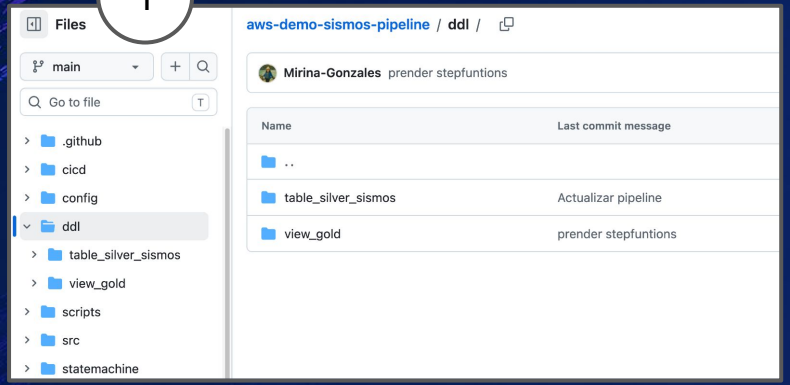
aws DuocUC

AWS SBG Chile
Student Builder Groups Chile

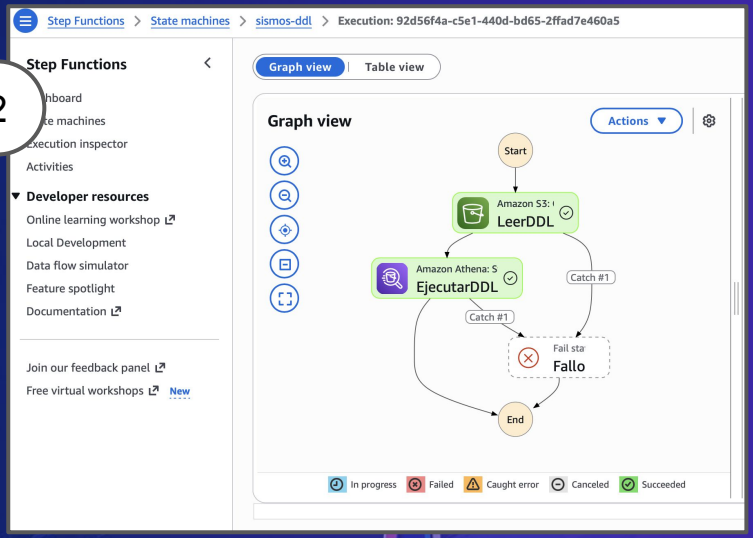
Crear las tablas

aws Student COMMUNITY DAY CHILE

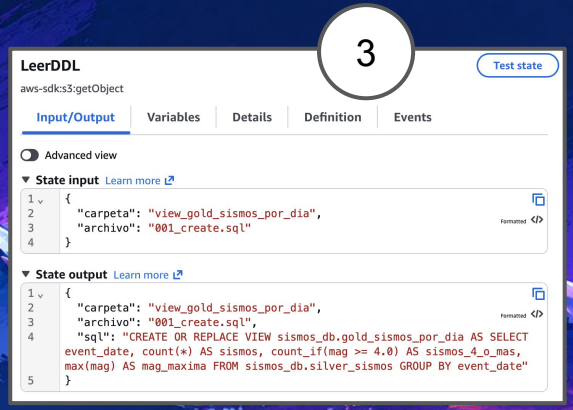
1



2

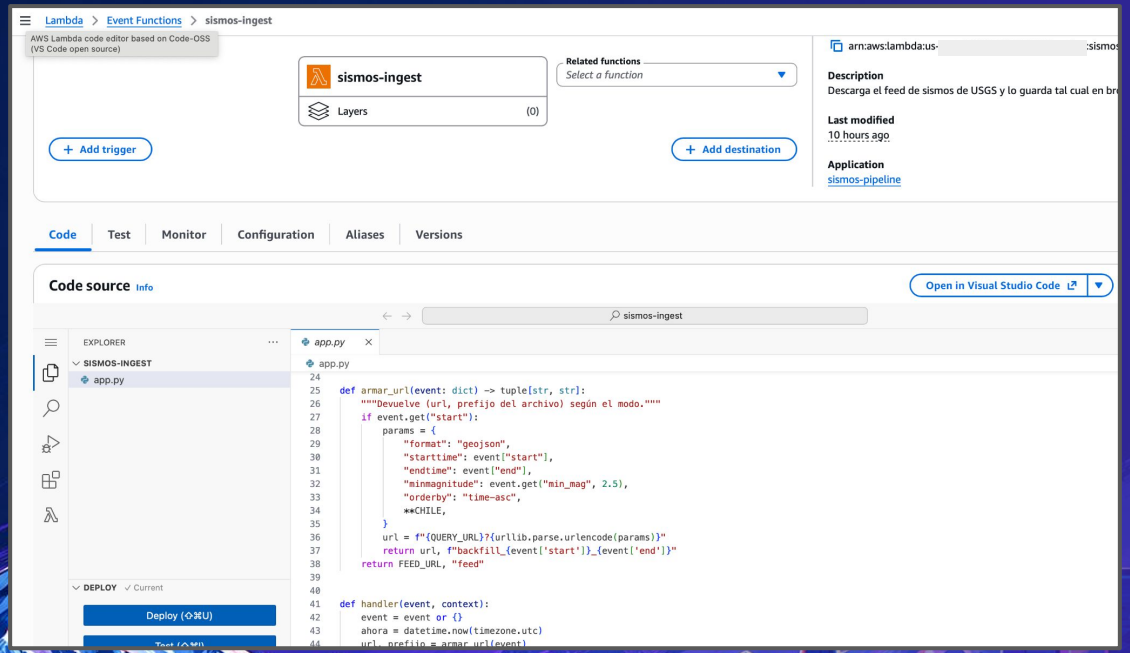


3



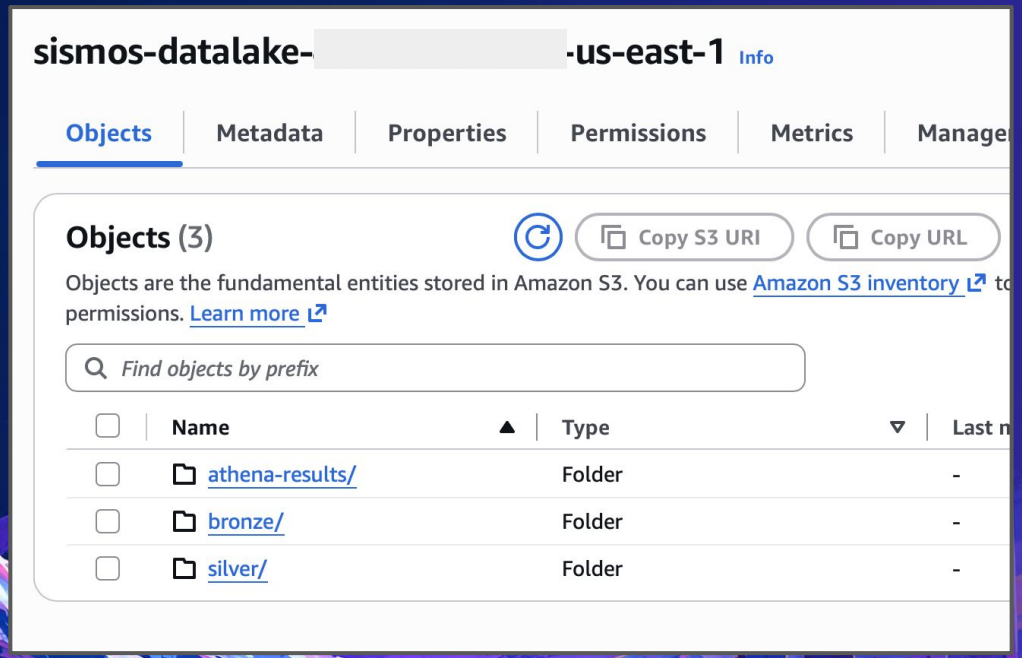
Ingesta

aws Student COMMUNITY DAY CHILE



Almacenamiento

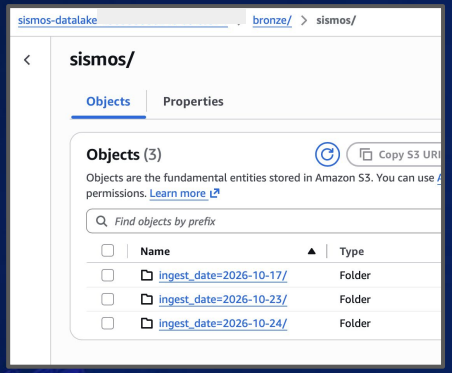
aws Student COMMUNITY DAY CHILE

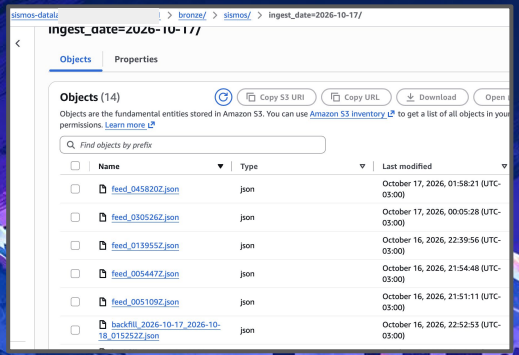


Almacenamiento

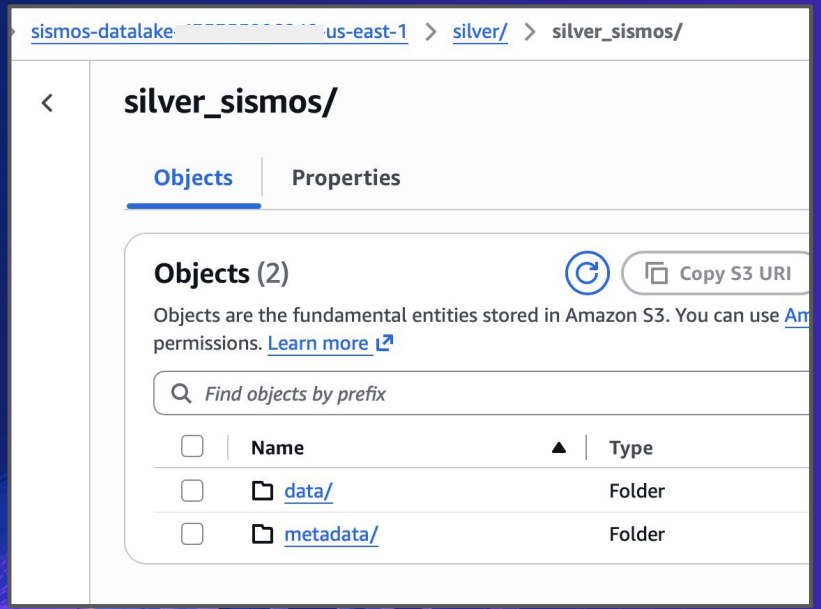
aws Student COMMUNITY DAY CHILE

Bronze



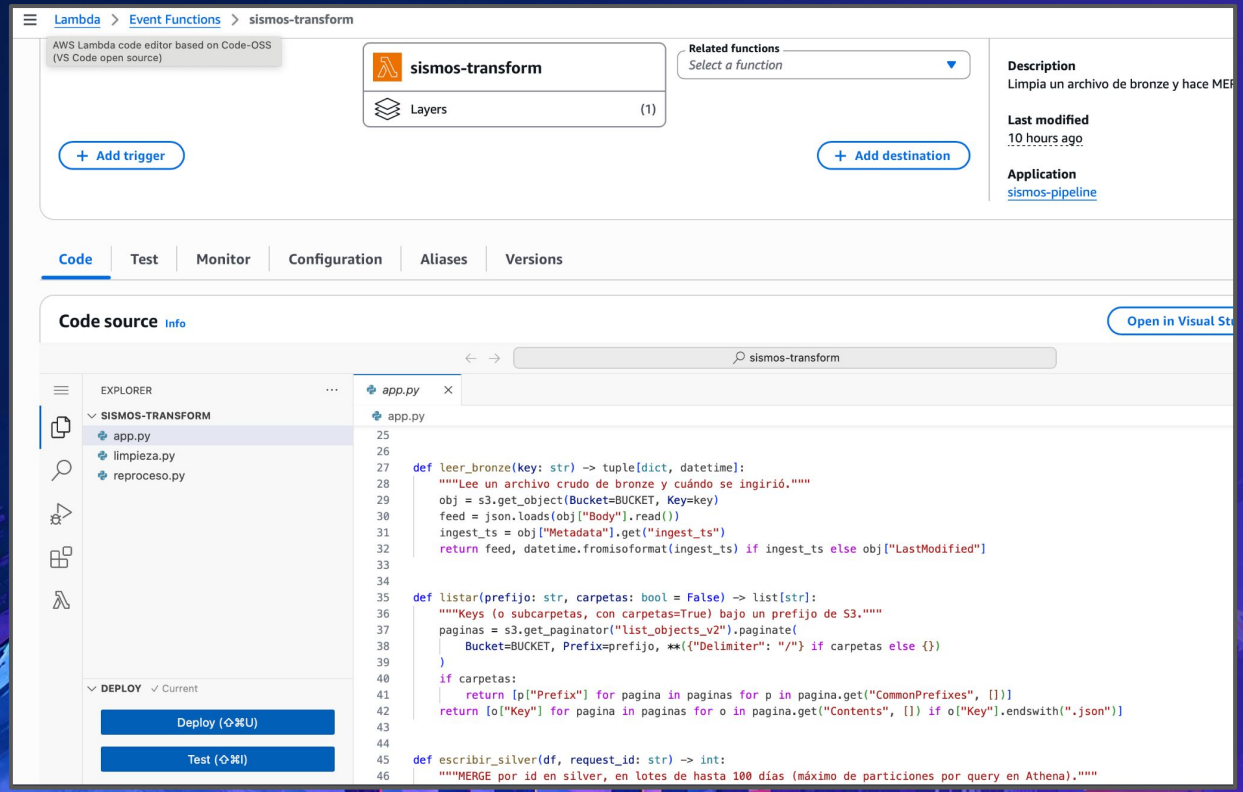


Silver

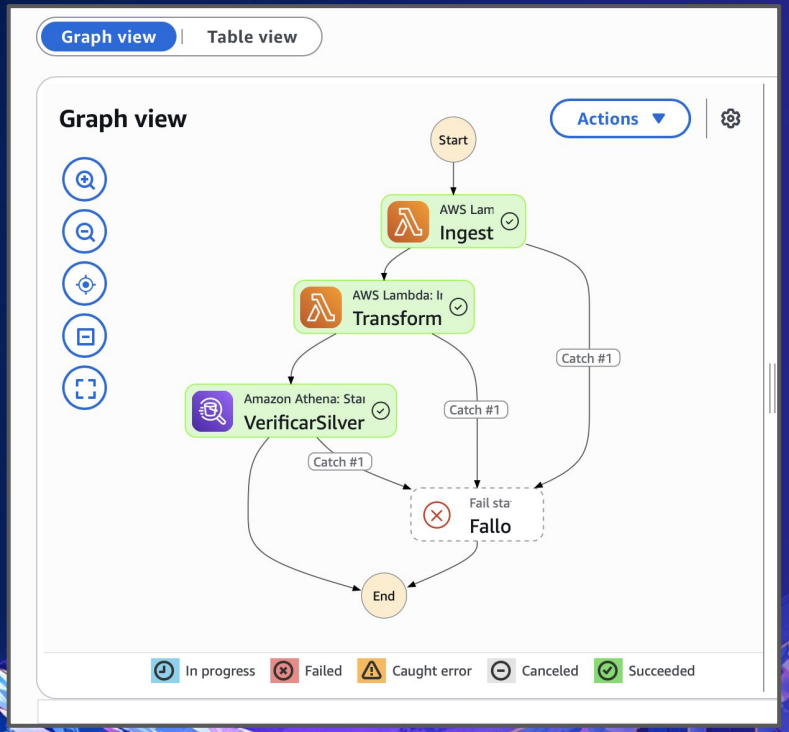


Transformación

aws Student COMMUNITY DAY CHILE



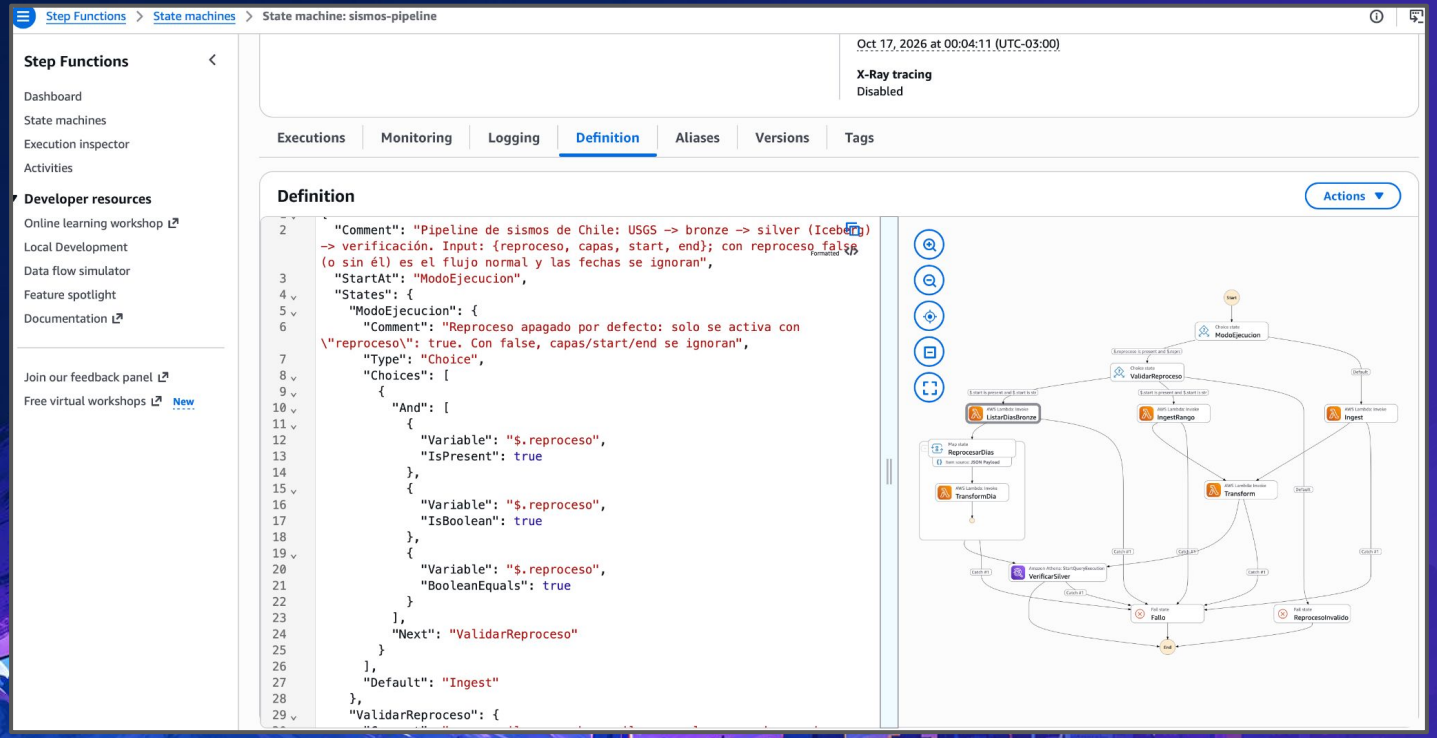
Orquestación



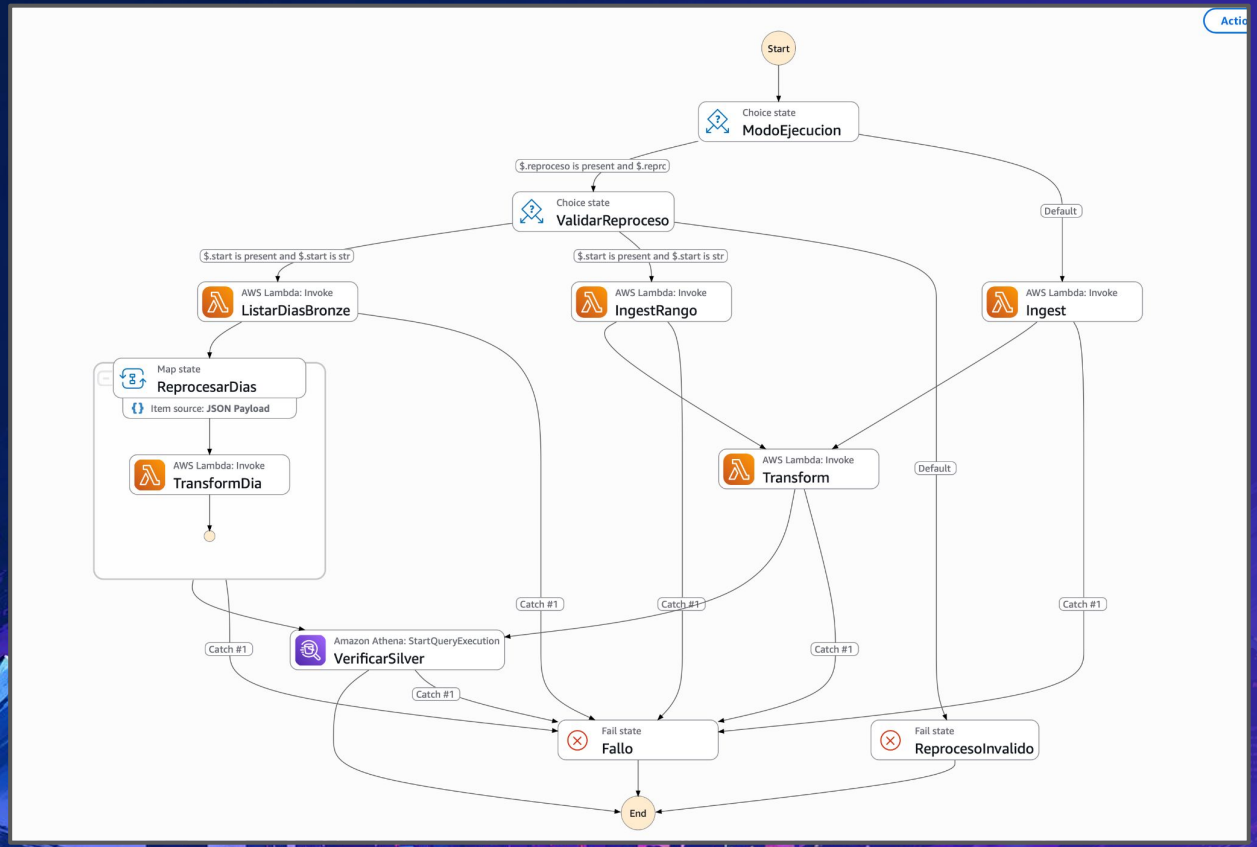
aws Student COMMUNITY DAY CHILE

Orquestación

aws Student COMMUNITY DAY CHILE

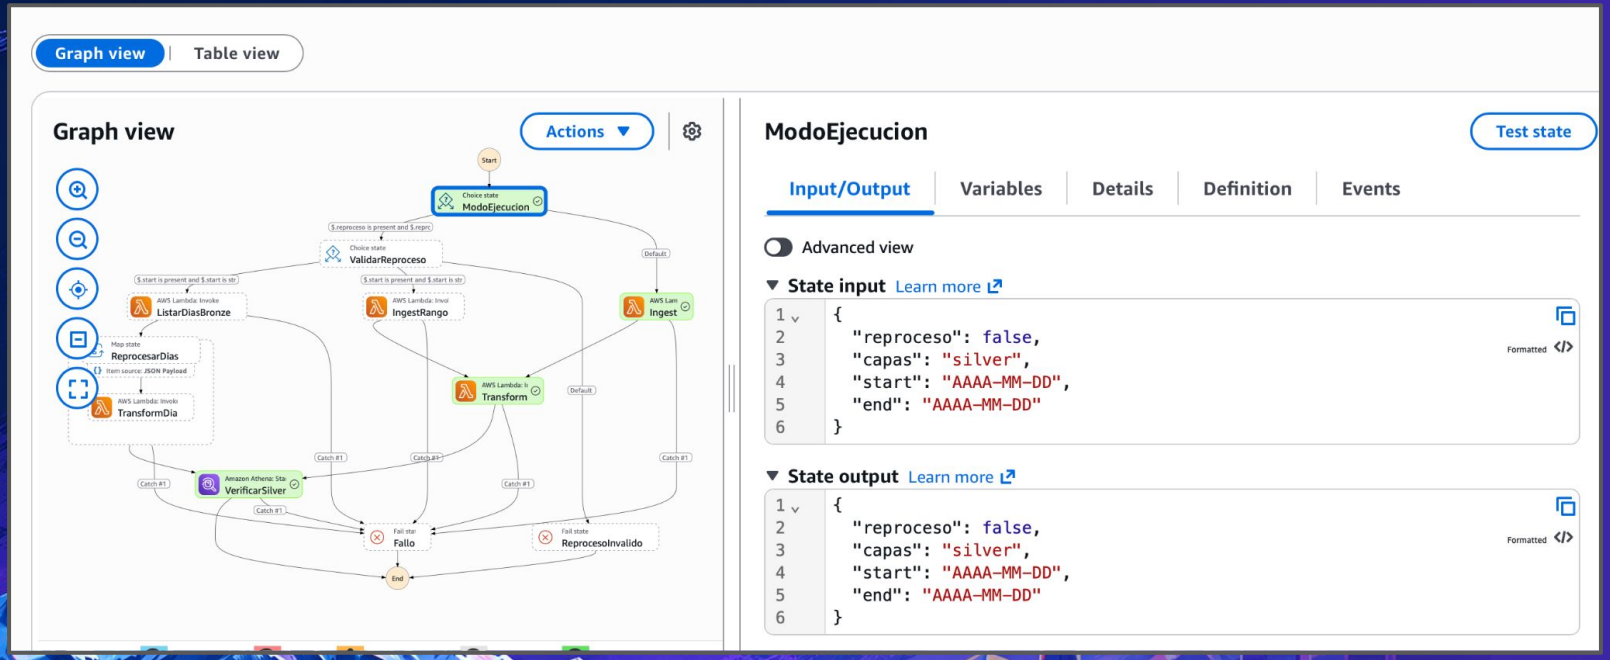


Orquestación



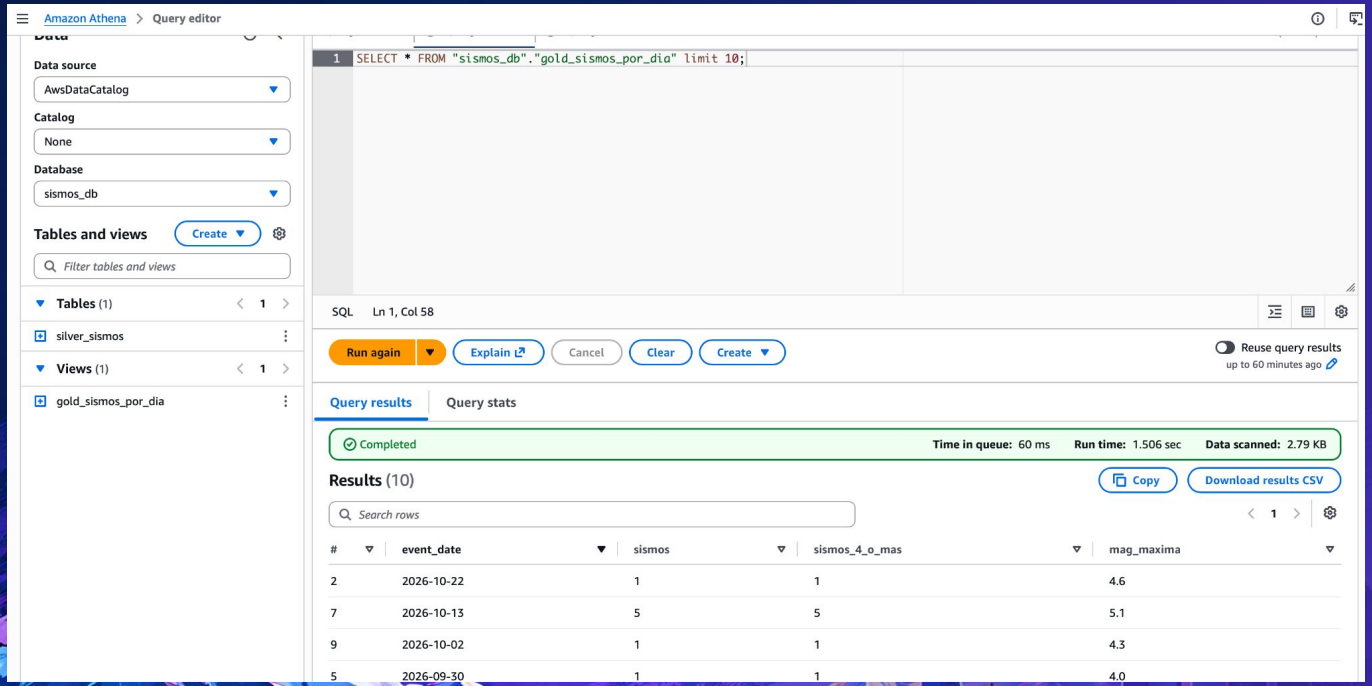
Orquestación – Reprocesos

aws Student COMMUNITY DAY CHILE



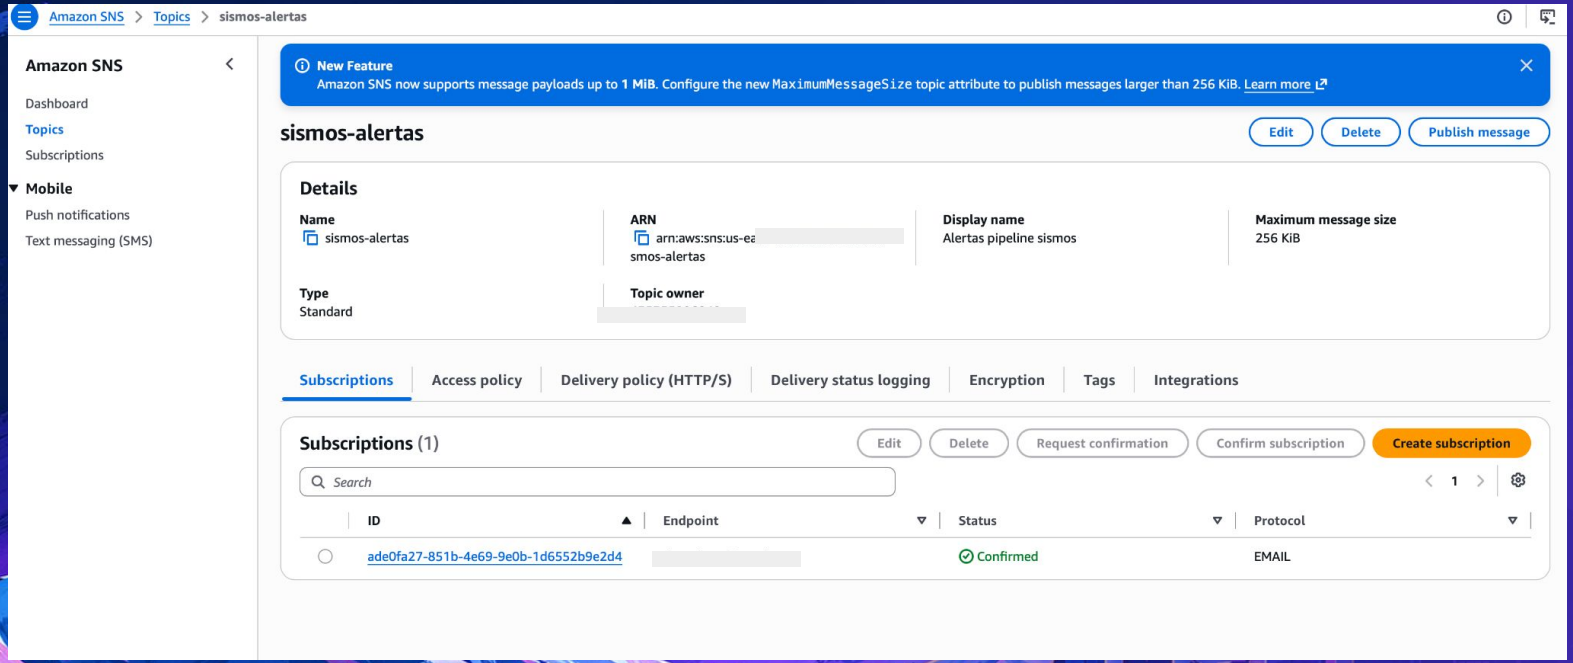
Serving

aws Student COMMUNITY DAY CHILE



Monitoreo

aws Student COMMUNITY DAY CHILE



1ra Edición

Demo

De la API de USGS a una respuesta en Athena



aws DuocUC

AWS SBG Chile
Student Builder Groups Chile

Tu primera ruta en datos

aws Student COMMUNITY DAY CHILE

1. **SQL**
2. **Python + pandas**
3. **Fundamentos AWS**
4. **Un proyecto propio**
5. **Certificarte**
6. **Comunidad**

Para empezar

- AWS Skill Builder (gratis)
- Kaggle: https://www.kaggle.com/
- Fundamentals of Data Engineering: Plan and Build Robust Data Systems – Reis, J. y Housley, M. (2022).
- AWS Certified Cloud Practitioner
- AWS Data Engineer Associate
- Data Analytics Lens

Necesitas un proyecto y empezar.

1ra Edición

¿Y cuántos sismos hubo?

La respuesta en Athena



aws DuocUC

AWS SBG Chile
Student Builder Groups Chile

1ra Edición



Mirina Gonzales

linkedin.com/in/mirina-gonzales-rodriguez/

github.com/Mirina-Gonzales

@techtalkswithmiri

https://mirina-gonzales.web.app/

¡Gracias! ¿Preguntas?

aws DuocUC AWS SBG Chile
Student Builder Groups Chile